

**PENERAPAN DATA PREPROCESSING DAN MULTIPLE LINEAR REGRESSION
PADA DATASET TRANSAKSI E-COMMERCE**

PEMBELAJARAN MESIN

Dosen Pengampu:
Ulfa Khaira, S.Komp., M.Kom.



Oleh:
Putri Prayesti F1E124067

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI
2026**

Deskripsi Dataset

Dataset yang digunakan adalah dataset transaksi e-commerce dengan nama dataset_penjualan_ecommerce_dirty_300.csv. Dataset awal terdiri dari 310 baris dan 16 kolom yang memuat informasi pelanggan, transaksi, produk, pembayaran, membership, hingga nilai total pembelian.

Variabel yang terdapat dalam dataset meliputi ID_Pelanggan, Usia, Jenis_Kelamin, Kota, Pendapatan, Kategori_Produk, Harga_Satuan, Jumlah, Diskon_Persen, Metode_Pembayaran, Membership, Rating, Lama_Pengiriman_Hari, Tanggal_Transaksi, Kode_Promosi, dan Total_Pembelian.

Target yang akan diprediksi adalah **Total_Pembelian**, yaitu nilai total transaksi pelanggan.

	ID_Pelanggan	Usia	Jenis_Kelamin	Kota	Pendapatan	Kategori_Produk	Harga_Satuan	Jumlah	Diskon_Persen	Metode_Pembayaran	Membership	Rating	Lama_Pengiriman_Hari	Tanggal_Transaksi	Kode_Promosi	Total_Pembelian
0	C0290	20.0	Laki-laki	Palembang	8115796.0	Fashion	1511628.0	2	20.0	COD	Bronze	4.4	5	2026-10-17	HEMAT15	2375930.0
1	C0010	53.0	Perempuan	Pekabaru	9559988.0	Elektronik	2971806.0	2	15.0	Kartu Kredit	Bronze	2.7	2	2026-01-10	TANPA_PROMO	4230548.0
2	C0058	31.0	Perempuan	Padang	3767951.0	Fashion	3080677.0	1	0.0	COD	Gold	3.9	5	2026-02-27	TANPA_PROMO	2539476.0
3	C0061	25.0	Laki-laki	Palembang	7670217.0	Olahraga	2787357.0	7	15.0	Transfer Bank	Gold	2.9	7	2026-03-02	GRATISONGKIR	10447610.0
4	C0026	33.0	Laki-laki	Palembang	7493105.0	Fashion	558822.0	1	10.0	Kartu Kredit	Bronze	2.5	2	2026-01-26	HEMAT15	1513269.0

```
print("Jumlah baris:", df.shape[0])
print("Jumlah kolom:", df.shape[1])

df.dtypes

df.describe()
```

	Usia	Pendapatan	Harga_Satuan	Jumlah	Diskon_Persen	Rating	Lama_Pengiriman_Hari	Total_Pembelian
count	303.000000	3.030000e+02	3.030000e+02	310.000000	306.000000	304.000000	310.000000	3.100000e+02
mean	37.270627	7.215513e+06	2.869623e+06	4.219355	13.006536	3.745724	4.387097	5.972289e+06
std	12.713320	6.006853e+06	4.078725e+06	4.189324	8.528446	0.773476	2.242245	3.891174e+06
min	5.000000	1.800000e+06	6.279100e+04	1.000000	0.000000	0.500000	1.000000	5.010670e+05
25%	26.000000	5.182309e+06	1.495311e+06	2.000000	5.000000	3.100000	2.000000	2.714230e+06
50%	39.000000	6.768519e+06	2.684613e+06	4.000000	15.000000	3.800000	4.000000	5.102208e+06
75%	46.500000	8.385601e+06	3.636552e+06	6.000000	20.000000	4.325000	6.000000	8.375151e+06
max	120.000000	7.500000e+07	5.000000e+07	50.000000	25.000000	7.000000	8.000000	1.760132e+07

Hasil Preprocessing

Tahap preprocessing dilakukan untuk memastikan data siap digunakan dalam pemodelan. Tahapan yang dilakukan meliputi pemeriksaan duplikat, missing value, nilai tidak wajar, konsistensi kategori, outlier, pengecekan potensi data leakage, penghapusan kolom yang tidak diperlukan, serta encoding data kategorikal.

Duplikat

Ditemukan 8 data duplikat pada dataset. Data tersebut kemudian dihapus sehingga jumlah data menjadi 302 baris.

```
print("Jumlah data duplikat:", df.duplicated().sum())
```

[9] ✓ 0.0s

... Jumlah data duplikat: 8

```
df[df.duplicated(keep=False)].sort_values(by=df.columns.tolist())
```

[10] ✓ 0.0s

...

	ID_Pelanggan	Usia	Jenis_Kelamin	Kota	Pendapatan	Kategori_Produk	Harga_Satuan	Jumlah	Diskon_Persen	Metode_Pembayaran	Membership	Rating	Lama_Pengiriman_Hari	Tanggal_Transaksi	Kode_Promosi	Total_Pembelian
41	C0025	45.0	Perempuan	Jambi	6480661.0	Olahraga	772314.0	2	20.0	Kartu Kredit	Silver	3.4	6	2026-01-25	HEMAT15	1366860.0
223	C0025	45.0	Perempuan	Jambi	6480661.0	Olahraga	772314.0	2	20.0	Kartu Kredit	Silver	3.4	6	2026-01-25	HEMAT15	1366860.0
69	C0060	32.0	Perempuan	Bengkulu	7276947.0	Fashion	3321060.0	3	0.0	COD	Bronze	4.0	3	2026-03-01	TANPA_PROMO	6104502.0
206	C0060	32.0	Perempuan	Bengkulu	7276947.0	Fashion	3321060.0	3	0.0	COD	Bronze	4.0	3	2026-03-01	TANPA_PROMO	6104502.0
13	C0088	24.0	Perempuan	Pekanbaru	8898796.0	Olahraga	2121079.0	1	0.0	E-Wallet	Silver	3.3	7	2026-03-29	GRATISONGKIR	2258922.0
300	C0088	24.0	Perempuan	Pekanbaru	8898796.0	Olahraga	2121079.0	1	0.0	E-Wallet	Silver	3.3	7	2026-03-29	GRATISONGKIR	2258922.0
26	C0114	43.0	Perempuan	Pekanbaru	7287978.0	Kecantikan	1217171.0	2	10.0	Transfer Bank	Gold	3.7	7	2026-04-24	GRATISONGKIR	2431909.0
56	C0114	43.0	Perempuan	Pekanbaru	7287978.0	Kecantikan	1217171.0	2	10.0	Transfer Bank	Gold	3.7	7	2026-04-24	GRATISONGKIR	2431909.0
275	C0189	46.0	Perempuan	Jambi	5935003.0	Rumah Tangga	853790.0	7	0.0	Kartu Kredit	Bronze	2.9	2	2026-07-08	PROMO10	4063892.0
305	C0189	46.0	Perempuan	Jambi	5935003.0	Rumah Tangga	853790.0	7	0.0	Kartu Kredit	Bronze	2.9	2	2026-07-08	PROMO10	4063892.0
125	C0262	44.0	Perempuan	Bengkulu	9802138.0	Olahraga	2630109.0	4	25.0	E-Wallet	Gold	3.0	2	2026-09-19	TANPA_PROMO	6072012.0
187	C0262	44.0	Perempuan	Bengkulu	9802138.0	Olahraga	2630109.0	4	25.0	E-Wallet	Gold	3.0	2	2026-09-19	TANPA_PROMO	6072012.0
191	C0278	23.0	Perempuan	Palembang	11566406.0	Elektronik	2684688.0	6	25.0	E-Wallet	Bronze	4.4	3	2026-10-05	TANPA_PROMO	8157507.0
303	C0278	23.0	Perempuan	Palembang	11566406.0	Elektronik	2684688.0	6	25.0	E-Wallet	Bronze	4.4	3	2026-10-05	TANPA_PROMO	8157507.0
283	C0294	20.0	Laki-laki	Bengkulu	6754507.0	Rumah Tangga	2151411.0	5	20.0	E-Wallet	Bronze	2.8	2	2026-10-21	PROMO10	5842088.0
294	C0294	20.0	Laki-laki	Bengkulu	6754507.0	Rumah Tangga	2151411.0	5	20.0	E-Wallet	Bronze	2.8	2	2026-10-21	PROMO10	5842088.0

Missing Value

Ditemukan missing value pada beberapa kolom. Untuk kolom numerik, missing value ditangani menggunakan median, sedangkan untuk kolom kategorikal digunakan modus. Setelah proses imputasi dilakukan, seluruh kolom sudah tidak memiliki missing value.

```
missing_value = df.isnull().sum()

print("Jumlah missing value setiap kolom:")
display(missing_value)
```

[13] ✓ 0.0s

... Jumlah missing value setiap kolom:

...

ID_Pelanggan	0
Usia	7
Jenis_Kelamin	0
Kota	6
Pendapatan	7
Kategori_Produk	6
Harga_Satuan	7
Jumlah	0
Diskon_Persen	4
Metode_Pembayaran	0
Membership	4
Rating	6
Lama_Pengiriman_Hari	0
Tanggal_Transaksi	0
Kode_Promosi	0
Total_Pembelian	0

dtype: int64

ID_Pelanggan	0
Usia	0
Jenis_Kelamin	0
Kota	0
Pendapatan	0
Kategori_Produk	0
Harga_Satuan	0
Jumlah	0
Diskon_Persen	0
Metode_Pembayaran	0
Membership	0
Rating	0
Lama_Pengiriman_Hari	0
Tanggal_Transaksi	0
Kode_Promosi	0
Total_Pembelian	0

dtype: int64

Nilai Tidak Wajar

Ditemukan beberapa nilai yang tidak sesuai dengan rentang logis, yaitu:

1. Usia sebesar 120 dan 5 tahun.
2. Rating sebesar 7 dan 0,5.

Nilai tersebut dianggap tidak valid karena usia pelanggan berada di luar rentang yang digunakan dan rating seharusnya berada pada rentang 1–5. Nilai tersebut diubah menjadi missing value dan kemudian ditangani menggunakan median.

Konsistensi Kategori

Pada Jenis_Kelamin ditemukan kategori P dan L yang kemudian distandarkan menjadi Perempuan dan Laki-laki.


Pada kolom Kota, variasi penulisan seperti JAMBI dan jambi juga distandarkan menjadi Jambi.

Outlier

Deteksi outlier dilakukan menggunakan metode IQR (Interquartile Range). Ditemukan outlier pada beberapa variabel, yaitu:

- Usia: 1 outlier
- Pendapatan: 2 outlier
- Harga_Satuan: 2 outlier
- Jumlah: 2 outlier
- Total_Pembelian: 1 outlier

Outlier tersebut tetap dipertahankan karena setelah ditinjau, nilainya masih memungkinkan terjadi dalam konteks transaksi dan tidak menunjukkan kesalahan input yang jelas.



Kolom yang Dihapus

ID_Pelanggan dihapus karena merupakan identifier dan tidak digunakan sebagai feature dalam model. Tanggal_Transaksi juga tidak digunakan sebagai feature karena tidak digunakan secara langsung dalam model regresi.

Data kategorikal telah melalui proses One-Hot Encoding sebagai bagian dari preprocessing.

Feature dan Target

Target yang digunakan dalam penelitian ini adalah:

Total_Pembelian

Feature yang digunakan dalam model adalah:

Feature	Keterangan
Usia	Karakteristik pelanggan yang dapat berkaitan dengan pola pembelian
Pendapatan	Merepresentasikan kemampuan finansial pelanggan
Harga_Satuan	Berkaitan dengan nilai produk yang dibeli
Jumlah	Menunjukkan banyaknya produk yang dibeli
Diskon_Persen	Merepresentasikan besarnya diskon transaksi
Rating	Merepresentasikan penilaian atau pengalaman pelanggan
Lama_Pengiriman_Hari	Merepresentasikan aspek layanan pengiriman

Pemilihan feature dilakukan berdasarkan relevansinya terhadap karakteristik pelanggan dan transaksi. ID_Pelanggan tidak digunakan karena hanya berfungsi sebagai identitas pelanggan.

Train-Test Split

Dataset dibagi menjadi data training dan data testing menggunakan `train_test_split` dengan perbandingan 80:20 dan `random_state=42`.

Hasil pembagian data:

- `x_train`: 241 baris, 7 feature
- `x_test`: 61 baris, 7 feature
- `y_train`: 241 data
- `y_test`: 61 data

Data training digunakan untuk membangun model, sedangkan data testing digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data yang belum digunakan saat training.

```
print("Jumlah observasi:")
print("X_train:", X_train.shape)
print("X_test :", X_test.shape)
print("y_train:", y_train.shape)
print("y_test :", y_test.shape)
```

[47] ✓ 0.0s

```
... Jumlah observasi:
X_train: (241, 7)
X_test : (61, 7)
y_train: (241,)
y_test : (61,)
```

Multiple Linear Regression

Pemodelan dilakukan menggunakan metode Multiple Linear Regression dengan tujuh feature yang telah dipilih. Model dilatih menggunakan data training:

$$\begin{aligned} \text{Total_Pembelian} = & \beta_0 + \beta_1 \text{Usia} + \beta_2 \text{Pendapatan} + \beta_3 \text{Harga_Satuan} \\ & + \beta_4 \text{Jumlah} + \beta_5 \text{Diskon_Persen} + \beta_6 \text{Rating} \\ & + \beta_7 \text{Lama_Pengiriman_Hari} \end{aligned}$$

Model kemudian digunakan untuk memprediksi Total_Pembelian pada data testing.

Intercept dan Koefisien

Hasil model menghasilkan intercept sebesar 6.367.140,90.

Koefisien masing-masing feature adalah:

Feature	Koefisien
Usia	3.769,25
Pendapatan	0,028007
Harga_Satuan	0,081059
Jumlah	-3.432,98
Diskon_Persen	-82.666,24
Rating	377,03
Lama_Pengiriman_Hari	-219,16

Sehingga persamaan regresinya adalah:

$$\begin{aligned} \text{Total_Pembelian} = & 6.367.140,90 + 3.769,25(\text{Usia}) + 0,028007(\text{Pendapatan}) + \\ & 0,081059(\text{Harga_Satuan}) - 3.432,98(\text{Jumlah}) - 82.666,24(\text{Diskon_Persen}) + \\ & 377,03(\text{Rating}) - 219,16(\text{Lama_Pengiriman_Hari}) \end{aligned}$$

```

*** Intercept: 6367140.903730614
***

```

	Feature	Koefisien
0	Usia	3769.251083
1	Pendapatan	0.028007
2	Harga_Satuan	0.081059
3	Jumlah	-3432.984795
4	Diskon_Persen	-82666.243792
5	Rating	377.034289
6	Lama_Pengiriman_Hari	-219.155810

Pemeriksaan Multikolinearitas


Pemeriksaan multikolinearitas dilakukan menggunakan correlation matrix dan Variance Inflation Factor (VIF).

Hubungan paling kuat ditemukan antara Pendapatan dan Jumlah dengan nilai korelasi sebesar -0,63. Meskipun menunjukkan hubungan negatif yang cukup kuat, hasil VIF menunjukkan seluruh feature memiliki nilai yang mendekati 1.

Nilai VIF tertinggi adalah:

Harga_Satuan = 1,014831

Karena seluruh nilai VIF berada jauh di bawah 5, tidak terdapat indikasi multikolinearitas yang berarti. Oleh karena itu, seluruh feature tetap digunakan dalam model.



	Feature	VIF
0	Usia	1.006104
1	Pendapatan	1.006464
2	Harga_Satuan	1.014831
3	Jumlah	1.008450
4	Diskon_Persen	1.005784
5	Rating	1.012111
6	Lama_Pengiriman_Hari	1.012835

Hasil Prediksi

Model digunakan untuk memprediksi Total_Pembelian pada 61 data testing. Contoh 10 hasil prediksi pertama:

	Aktual	Prediksi	Error
0	9681654.0	6.949554e+06	2.732100e+06
1	2151189.0	4.808127e+06	-2.656938e+06
2	1243409.0	5.474243e+06	-4.230834e+06
3	9238906.0	6.570242e+06	2.668664e+06
4	6453096.0	5.306412e+06	1.146684e+06
5	6905219.0	5.384698e+06	1.520521e+06
6	16620310.0	6.601306e+06	1.001900e+07
7	1012948.0	4.999223e+06	-3.986275e+06
8	3337806.0	5.546466e+06	-2.208660e+06
9	2617082.0	5.809194e+06	-3.192112e+06

Nilai error dihitung dengan:

$$\text{Error} = \text{Aktual} - \text{Prediksi}$$

Error positif menunjukkan model melakukan underprediction, sedangkan error negatif menunjukkan model melakukan overprediction.

RMSE dan R² Score

Hasil evaluasi model adalah:


- RMSE = Rp4.123.330,05
- R² Score = 0,0563

RMSE sebesar sekitar Rp4,12 juta menunjukkan bahwa besar kesalahan prediksi model masih cukup tinggi.

Sementara itu, R² sebesar 0,0563 menunjukkan bahwa model hanya mampu menjelaskan sekitar 5,63% variasi Total_Pembelian pada data testing. Dengan demikian, sebagian besar variasi nilai pembelian belum dapat dijelaskan oleh feature yang digunakan dalam model.


Visualisasi

a. Pendapatan terhadap Total Pembelian




Visualisasi menunjukkan bahwa titik data cukup tersebar dan tidak membentuk pola linear yang kuat. Hal ini sejalan dengan kemampuan model yang masih rendah dalam menjelaskan variasi Total_Pembelian.

b. Actual vs Predicted



Pada visualisasi Actual vs Predicted, semakin dekat titik dengan garis diagonal berarti prediksi semakin mendekati nilai aktual. Pada hasil model, masih terdapat banyak titik yang cukup jauh dari garis tersebut. Hal ini menunjukkan adanya perbedaan yang cukup besar antara nilai aktual dan hasil prediksi.

c. Residual Plot



Residual digunakan untuk melihat selisih antara nilai aktual dan prediksi. Plot residual dapat digunakan untuk melihat apakah masih terdapat pola tertentu pada kesalahan prediksi yang belum dapat ditangkap oleh model.

Interpretasi

Secara keseluruhan, model Multiple Linear Regression yang dibangun belum memiliki performa prediksi yang baik.

Nilai R^2 yang hanya sebesar 0,0563 menunjukkan bahwa feature yang digunakan hanya menjelaskan sekitar 5,63% variasi Total_Pembelian. Selain itu, RMSE sebesar Rp4,12 juta tergolong besar jika dibandingkan dengan nilai rata-rata Total_Pembelian yang berada di sekitar Rp5,97 juta.

Koefisien model menunjukkan beberapa hubungan positif dan negatif. Misalnya, Diskon_Persen memiliki koefisien negatif sebesar sekitar Rp82.666 untuk setiap kenaikan satu poin persentase, dengan asumsi feature lainnya tetap. Sementara itu, Pendapatan memiliki koefisien positif sebesar 0,028007.

Namun, koefisien tersebut perlu dipahami sebagai hubungan dalam model, bukan sebagai bukti hubungan sebab-akibat. Rendahnya performa model menunjukkan bahwa feature yang digunakan belum cukup untuk menjelaskan variasi nilai Total_Pembelian. Kemungkinan terdapat faktor lain dalam transaksi yang lebih berpengaruh terhadap target.

Kesimpulan

Berdasarkan proses yang telah dilakukan, dataset e-commerce berhasil melalui tahap preprocessing yang meliputi penanganan duplikat, missing value, nilai tidak wajar, konsistensi kategori, outlier, penghapusan kolom yang tidak diperlukan, serta encoding data kategorikal.

Model Multiple Linear Regression dibangun menggunakan tujuh feature, yaitu Usia, Pendapatan, Harga_Satuan, Jumlah, Diskon_Persen, Rating, dan Lama_Pengiriman_Hari, dengan Total_Pembelian sebagai target.

Hasil evaluasi menunjukkan RMSE sebesar Rp4.123.330,05 dan R^2 sebesar 0,0563. Hasil tersebut menunjukkan bahwa model masih memiliki kemampuan prediksi yang rendah dan belum cukup baik untuk digunakan dalam memprediksi data baru secara akurat.

Meskipun demikian, proses ini telah menunjukkan penerapan tahapan data preprocessing, feature selection, train-test split, Multiple Linear Regression, pemeriksaan multikolinearitas, prediksi, evaluasi, dan visualisasi secara menyeluruh. Performa model selanjutnya dapat ditingkatkan dengan menggunakan feature yang lebih relevan atau mencoba metode pemodelan regresi lainnya.